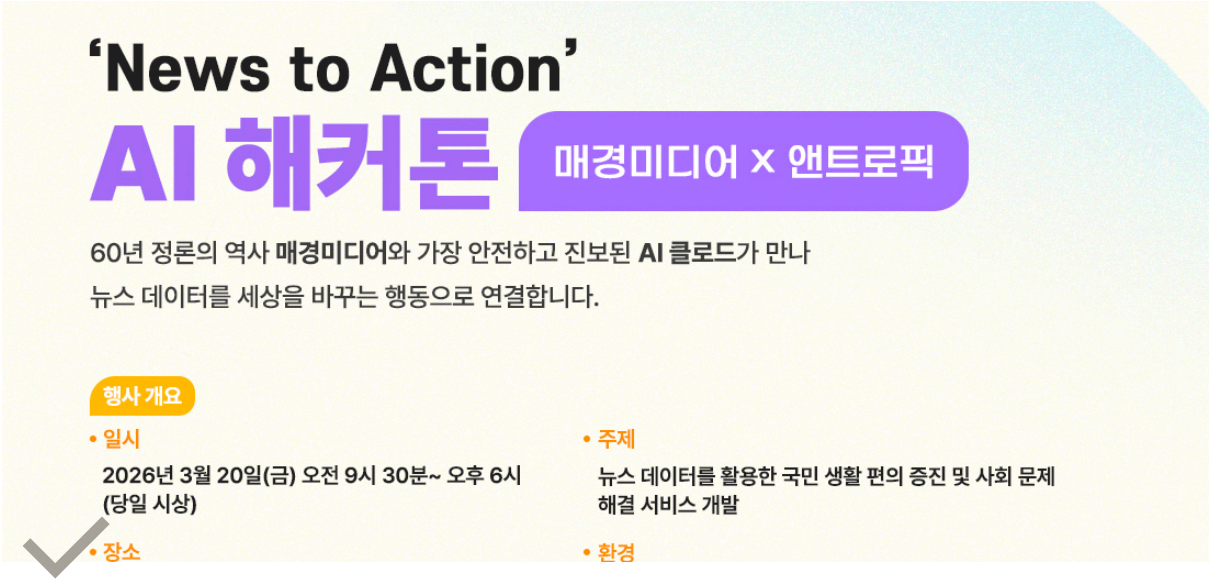


News-TODO | 매경미디어 X 앤스로픽 해커톤

개요	News-TODO는 인공지능을 통해 소상공인들에게 매장에 필요한 뉴스 정보를 요약해주고, 이에 맞춤화된 행동대응을 알려주는 실전형 뉴스 요약 서비스입니다.
기간	2026년 2월 24일 → 2026년 3월 20일
URL	발표자료
기술	FastAPI Python
팀원 구성	**AI(2)**, FE(1), BE(1)
FE 기여도	20
AI 기여도	50
BE 기여도	30

역할 기여도	50

프로젝트 개요

매경미디어와 앤스로픽이 공통 주관한 ‘News to Action’ AI 해커톤에 참여하여, 소상공인들에게 인공지능을 통해 매장에 필요한 뉴스 정보를 요약해주고 행동대응을 알려주는 **실전형 뉴스 요약 서비스**를 개발했습니다.

프로젝트 설명

소상공인들을 위한 맞춤형 뉴스 알림 및 행동강령을 알려주는 서비스입니다.

> 💡 왜 필요한가?

아무리 많은 양질의 뉴스가 쏟아져나온다고 해도, 결국 그게 도움이 되기 위해서는 사용자에게 그 내용이 전달되어야 합니다. 그러나 소상공인들은 가게 운영을 위한 준비를 하느라 바쁘거나, 혹은 전자기기에 익숙치 않아 실시간으로 올라오는 뉴스를 제대로 확인하지 못할 수 있습니다.

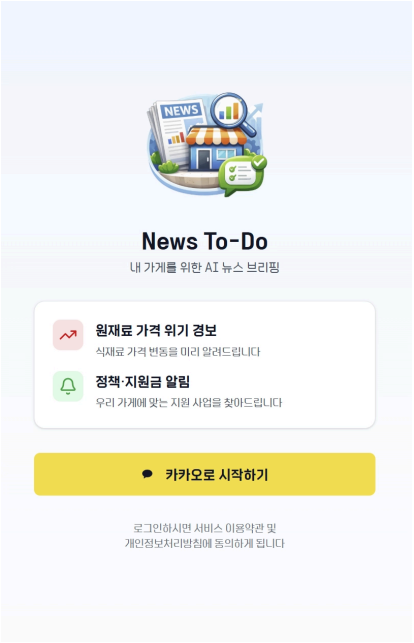
이런 소상공인들을 위해, 기본적인 가게 정보와 메뉴를 등록해둔다면 이를 바탕으로 관련된 뉴스와 함께 어떻게 대응해야 할 지 맞춤화된 행동강령을 알려주는 서비스를 개발하였습니다. 저희 서비스를 통해 소상공인들은 아래와 같은 효과를 누릴 수 있습니다.

1. 가게/메뉴/트렌드에 따른 맞춤 요약된 뉴스를 전달받을 수 있다.
2. 전달받은 뉴스를 통해 어떤 대응이 필요한지 AI에게 추천받을 수 있다.
3. AI가 자동으로 뉴스 요약/행동대응 추천을 해주기에 굳이 시간을 들이지 않아도 간편하게 필요한 정보를 알 수 있다.

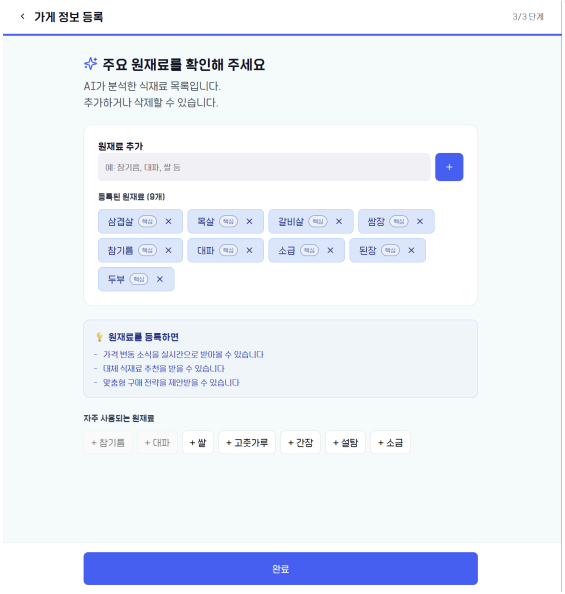
프로젝트 의도를 위해 제공하는 핵심 기능은 아래와 같습니다.

- 회원가입/로그인을 통한 회원정보 저장
- 가게 사진/원재료/매출 등 가게 정보 저장
- 기입된 가게 정보를 바탕으로 DB에 기록된 연관된 뉴스 추천
- 뉴스 요약/추천 및 해당 내용에 대한 행동 방안 제시

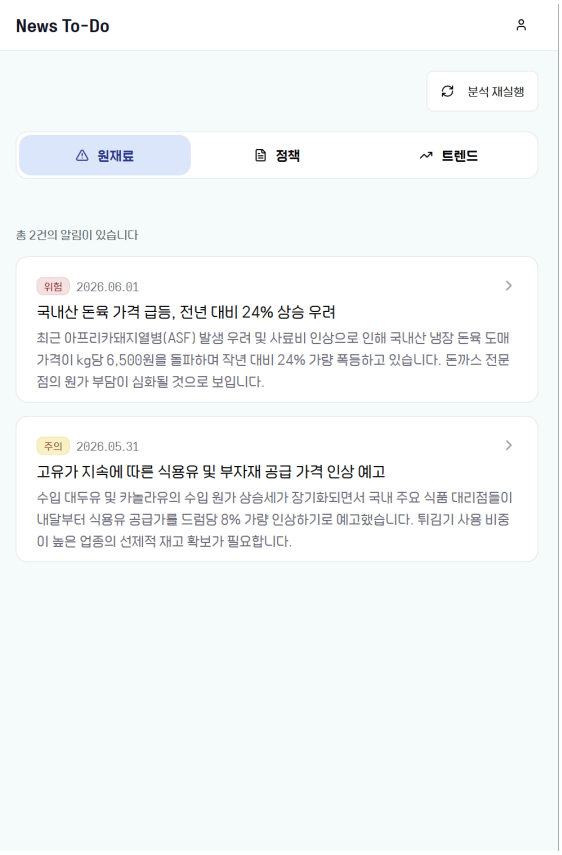
실제 서비스 화면



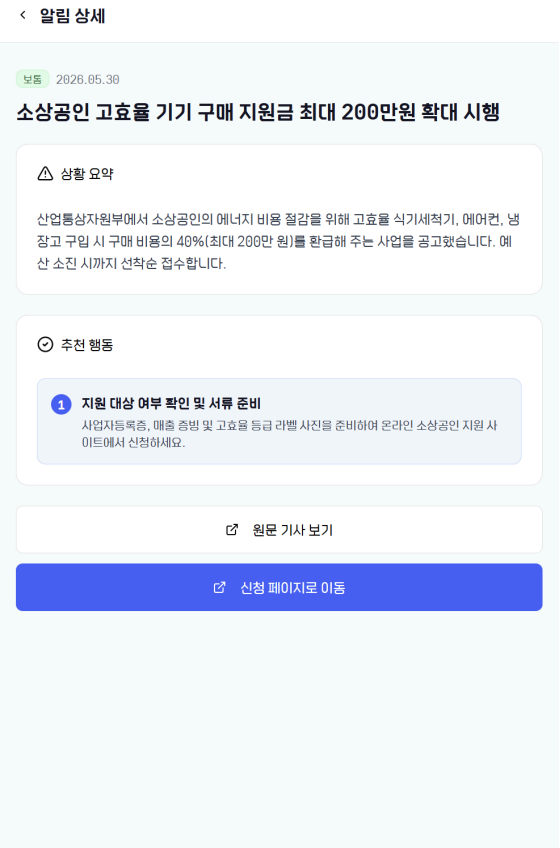
- 카카오 소셜 로그인을 통한 서비스 회원 가입



- 회원가입 후 가게 정보 입력
  - 가게 사진, 주요 원재료와 같이 가게와 관련된 정보를 입력
  - 이후 연관 기사 조회 시 등록한 가게 정보가 사용됨



- 원재료/정책/트렌드 총 3가지 카테고리 내에서 뉴스 추천
- 뉴스는 회원가입 시 사용자가 입력한 가게 정보를 기반으로 관련 뉴스가 조회됨



- 뉴스를 누를 시 상세 조회로 이동
  - 뉴스 요약 및 내용을 바탕으로 AI가 행동을 추천
  - 원문 기사 보기 및 필요 시 연관 페이지로 이동 가능



- 마이페이지에서 정보 수정 가능
    - 사용자는 가게 이미지를 재업로드하거나, 매출 현황, 가게 원재료 수정 등을 통해 가게에 새로운 정보가 생겼을 시 원하는 때에 바로 바로 수정 가능

담당 기능 개발

💡 **AI를 활용한 추천/검색 시스템 (RAG) 개발**

1. 한국어 특화 임베딩 모델 도입 및 VectorDB 구조 최적화

🤔 도입 배경 및 고민

- LLM이 뉴스를 분석하려면 기사를 벡터화하여 검색해야 했습니다. 처음에는 범용적인 OpenAI의 임베딩 API 사용을 고려했으나, 1) API 호출 비용과 지연 시간 문제, 2) 한국어 뉴스 특유의 경제/정책 용어에 대한 의미 파악 정확도 저하 우려가 있었습니다.

💡 해결책 및 기술적 의사결정

- **한국어 특화 로컬 모델 선택:** 한국어 자연어추론(NLI)과 의미적 텍스트 유사도(STS) 데이터셋으로 파인튜닝되어 성능이 검증된 `jhgan/ko-sroberta-multitask` 모델을 채택했습

니다. 이를 통해 로컬 환경에서 비용 없이 빠르고 정확하게 뉴스 기사를 임베딩할 수 있었습니다.

- **도메인 격리(Isolation)를 위한 멀티 컬렉션 설계:** 모든 뉴스를 하나의 DB에 넣을 경우, '식재료'를 검색할 때 '트렌드' 뉴스가 섞여 나오는 노이즈(Noise) 문제가 발생했었습니다. 이를 원천에 미리 차단하기 위해 ChromaDB의 컬렉션을 목적에 따라 3개 (`news_ingredient`, `news_policy`, `news_trend`)로 물리적으로 분리하여 검색의 정밀도를 극대화했습니다.

```
# 용도별 컬렉션을 분리하여 검색 노이즈 원천 차단
LAYER_TO_COLLECTION = {
    "layer1": "news_ingredient", # 원재료 위기 분석 전용
    "layer2": "news_policy",     # 정책 분석 전용
    "layer3": "news_trend",      # 트렌드 분석 전용
}
```

---

2. 컨텍스트 희석 방지를 위한 동적 검색 알고리즘

🤔 도입 배경 및 고민

- 가게에서 사용하는 모든 원재료(예: 대파, 소금 등 보조 재료 포함) 뉴스를 전부 RAG로 LLM에게 넘겨주자, 정작 중요한 핵심 원재료(예: 돼지고기)에 대한 정보가 희석되어 LLM이 엉뚱한 대답을 하거나 관련 없는 뉴스를 가져오는 현상이 발생했습니다. 이로 인한 프롬프트 토큰 낭비도 계속 이어져 모든 원재료를 LLM에 프롬프트로 넘겨주면 안된다고 판단했습니다.

💡 해결책 및 기술적 의사결정

- **중요도(Importance) 기반의 가중치 검색(Top-K) 차등 적용:** 가게 프로필의 원재료를 '핵심(1)', '중요(2)', '보조(3)'로 나누고, 1순위는 Top-5, 2순위는 Top-2만 검색하며, 3순위는 검색에서 제외하는 로직을 짰습니다. 이를 통해 프롬프트의 신호 대 잡음비를 비약적으로 상승시켰음을 실제 테스트 시 확인할 수 있었습니다.
- **LLM의 어텐션(Attention) 특성을 고려한 이중 정렬 로직:** LLM은 프롬프트의 앞쪽에 위치한 정보를 더 중요하게 인지하는 특성이 있습니다. 따라서 단순 유사도 순이 아니라, ①원재료 중요도 오름차순(핵심 우선) ➔ ②코사인 유사도 내림차순으로 이중 정렬하여 LLM이 가장 치명적인 위기 정보부터 읽어들이도록 설계했습니다.

```
# 핵심 재료는 많이(Top 5), 보조 재료는 검색 생략하여 LLM 컨텍스트 오염 방지
TOP_K_BY_IMPORTANCE = {1: 5, 2: 2}
```

```
# ... (검색 수행 후) ...
# LLM이 가장 중요한 핵심 원재료 정보를 먼저 읽도록(Attention 최적화) 이중 정렬 적용
all_news.sort(key=lambda x: (x["importance"], -x["similarity"]))
```

---

3. 환각 억제 및 실질적 액션 도출을 위한 ReAct 에이전트 설계

🤔 도입 배경 및 고민

- 단순한 RAG 방식으로는 소상공인에게 유효하지 않고 뻔한 대답만 생성되었습니다. 또한 뉴스와 상관없는 정보(환각)를 지어내는 문제도 통제해야 했습니다.

💡 해결책 및 기술적 의사결정

- **ReAct 기반 프롬프트 패턴 적용:** LLM이 즉시 결론을 내지 못하게 하고, 반드시 `[Thought]` (이 뉴스가 이 가게의 매출/원재료와 진짜 관련이 있는가?) 단계를 거쳐 논리적 검증을 한 뒤에만 `[Action]` (구체적으로 어떻게 대처할 것인가?)을 도출하도록 프롬프트를 설계했습니다.
- **데이터 기반의 재무적 타격 추산 지시:** 프롬프트에 사용자의 '월 매출'과 '배달 비중' 변수를 동적으로 주입하고, "원재료 인상 시 월 비용 증가액을 계산하라"는 명시적 제약을 두어 프롬프트가 수치적으로 고도화된 답변을 내놓을 수 있게 구성했습니다.

```
prompt = f"""
# ... (변수 주입부 생략) ...
[Thought 1] 각 뉴스가 위 가게의 핵심·중요 원재료와 직접 연관이 있는지 판단하세요.
[Action 1] 영향이 있는 뉴스만 선별하세요. 없으면 빈 배열 반환.
[Thought 2] 영향이 있다면, 월 매출 {monthly_revenue:,}원 기준으로 재무적 영향을 추정하세요.
[Action 2] 실행 가능한 액션 3가지를 구체적 수치와 함께 제시하세요.
"""
```

트러블슈팅

✨ 문제 배경

RAG를 구현하는 과정에서 모든 원재료나 키워드를 동일한 비중으로 검색할 경우, 덜 중요한 정보가 컨텍스트 윈도우를 차지해 LLM이 노이즈에 매몰되는 환각 문제가 발생했습니다. 반대로 트렌드 분석에서는 검색 범위가 너무 좁아 의미 있는 결과를 도출하지 못하거나 검색 결과가 나오지 않는 등 위험성이 존재했습니다.

💡 해결 방법

RAG의 Retrieval 계층을 각 Layer 에이전트의 '목적'에 맞춰 이원화(Precision vs Recall)하는 전략을 적용했습니다.

- **Layer 1 (원재료 - Precision 중심): 개체 중요도 기반 동적 Chunking 할당 (Dynamic Top-K)** 기법을 구현했습니다. Vision API가 분류한 원재료 중요도 배지에 따라 핵심 식자재는 `Top-K = 5`, 중요 식자재는 `Top-K = 2`, 보조 조미료는 `검색 생략`으로 동적 제한을 두었습니다. 결과적으로 가장 영향력이 큰 위기 징후만 밀도 있게 프롬프트에 주입하여 토큰 비용을 최소화하고 추론 정확도를 높였습니다.
- **Layer 3 (트렌드 - Recall 중심): 다중 쿼리 생성 및 후기 융합 (Multi-Query & Late-Fusion)** 기법을 고안했습니다. LLM 의존도를 낮추기 위해 코드 단에서 ① 유저 업종 특화 프롬프트("한식당 배달 소비 패턴"), ② 범용 확장 프롬프트("외식업 전체 인기 메뉴 트렌드") 두 개의 쿼리를 병렬 생성하여 ChromaDB에 동시 타격(Multi-Targeting)했습니다. 이후 반환된 2개의 Document 세트를 병합하고, Set 자료구조로 중복 URL을 제거한 뒤 Cosine Similarity 기준으로 재정렬(Re-ranking) 알고리즘을 거쳐 최종 컨텍스트를 구성했습니다.

📝 알게된 점

RAG의 성능은 단순한 임베딩 모델의 성능뿐만 아니라, 검색된 문서를 필터링, 제한, 조립하는 파이프라인(Retrieval Strategy) 설계 로직에 크게 의존함을 배울 수 있었습니다. 상황에 따라 토큰을 깎아내거나 쿼리를 다각화하는 등의 검색 전략이 AI를 다루는 데에 있어서 또한 필수적인 역량임을 이해할 수 있었습니다.

향후 개선 계획

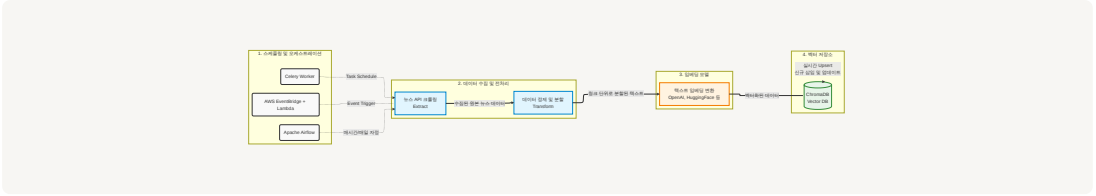
1. 실시간 데이터 파이프라인 구축

- **현재의 한계:**

  `build_chromadb.py` 스크립트를 통해 로컬에서 배치 형태로 정적인 JSONL 파일을 읽어 DB를 구축하는 구조입니다. 이는 해커톤 개최 측에서 제공한 1년치 뉴스에 대해서만 DB를 구축해놓은 상태이기 때문에, 실시간 뉴스에 대해서는 관련 정보를 알 수 없습니

다. 현재 시장 정보에 맞춘 행동 대응을 알려주는 서비스인 만큼, 실시간 뉴스 데이터를 받지 못한다는 것이 큰 한계입니다.

- **개선 방안:**
  - **스트리밍 기반 파이프라인 구축:** Airflow, Celery 혹은 클라우드 환경(AWS EventBridge + Lambda)을 활용해 매시간/매일 자정에 뉴스 API를 크롤링합니다. 이후 임베딩을 거쳐 실시간으로 ChromaDB에 Upsert(업데이트 및 삽입)하는 자동화된 데이터 파이프라인(Data Ops)을 구축할 수 있습니다.



2. RAG 시스템 자동 평가 지표 도입

- **현재의 한계:**
  - "LLM이 생성한 액션 플랜이 진짜 유용한가?", "검색된 뉴스가 정말 원재료 위기와 관련이 있는가?"를 판단하는 유효성 기준이 현재로써는 없는 상황입니다.
- **개선 방안 (Improvement):**
  - **정량적 평가 프레임워크(Ragas, TruLens 등) 도입:**
    1. **Context Precision(검색 정밀도):** ChromaDB가 제대로 된 뉴스를 가져왔는지
    2. **Faithfulness(사실성):** Claude가 제공한 액션 플랜이 뉴스의 팩트에 기반했는지(환각 여부)
       위 두 가지 지표를 자동 채점하는 파이프라인을 구성하여, 추후 임베딩 모델을 교체하거나 프롬프트를 수정할 때 정량적인 성능 비교가 가능하도록 CI/CD 환경을 구축합니다.